국민대학교 KPSC & AIM 스터디 – 강화학습을 이용한 체스 AI 만들기

Introduction to RL, Week 10

Chris Ohk
utilForever@gmail.com

카트폴(Cartpole)

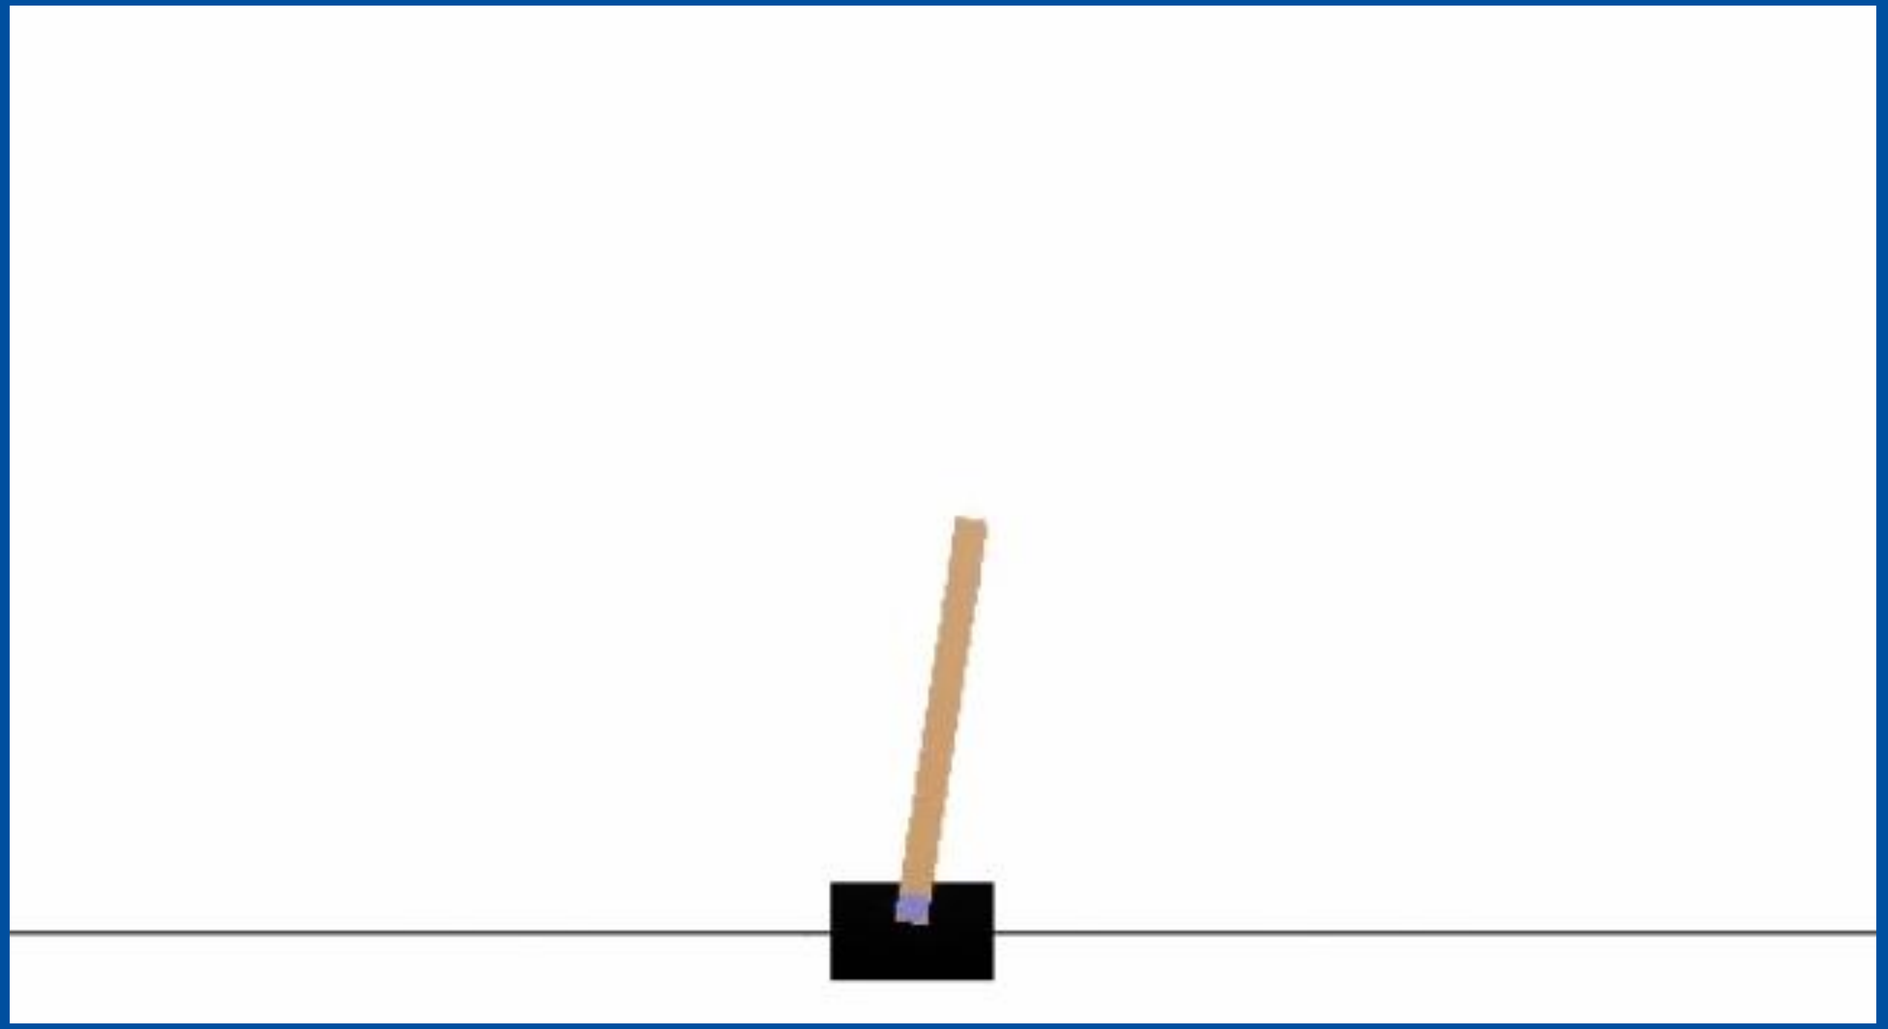

카트폴(Cartpole)

- 검은색 상자(카트)를 $+1, -1$의 힘으로 밀어 갈색 막대(폴)이 넘어지지 않게 하는 문제
- 카트의 위치 x가 ± 2.5를 벗어나거나 θ가 $\pm 15°$를 벗어나면 에피소드가 끝난다.

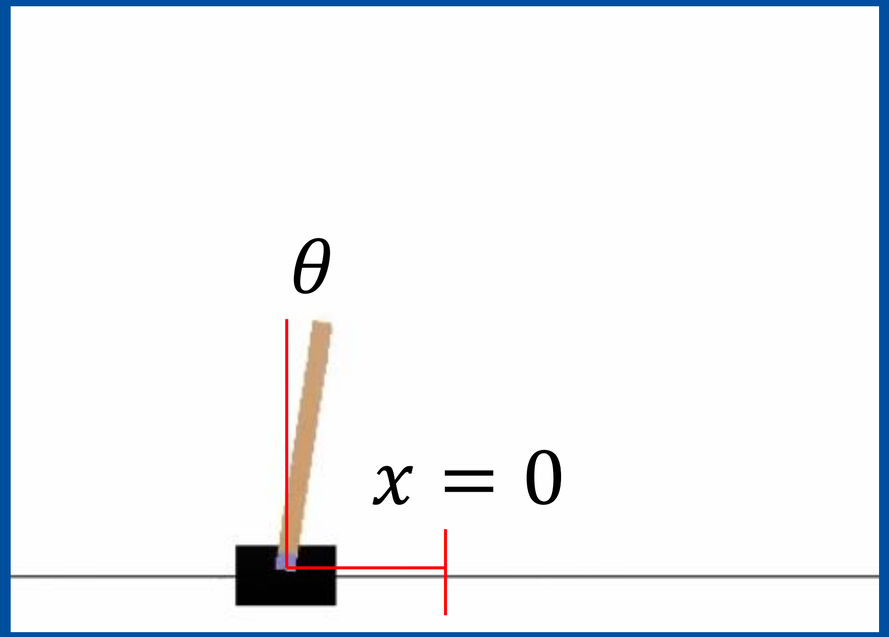

카트폴(Cartpole)

상태 s

$$s = \begin{bmatrix} x \\ \dot{x} \\ \theta \\ \dot{\theta} \end{bmatrix}$$

위치
속도
각도
각속도

행동 a

$$a = \begin{bmatrix} +1 \\ -1 \end{bmatrix}$$

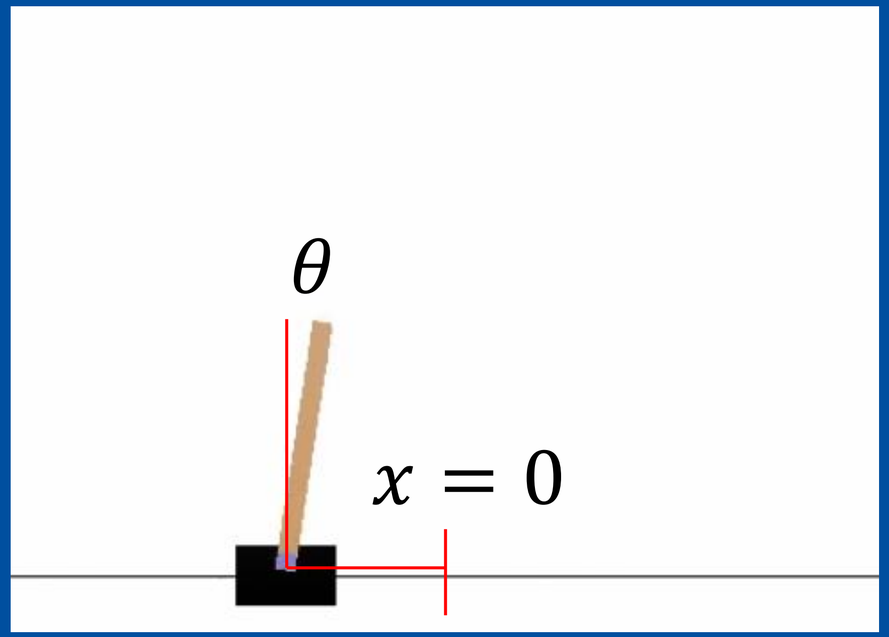

카트폴(Cartpole)

- 상태의 위치, 속도, 각도, 각속도 모두 연속적인 실수다.
- 그러므로 카트폴의 경우에는 테이블을 만들어 풀 수 없고,
  큐함수를 근사하는 함수를 만들어야 한다. → 인공신경망을 이용

DQN

- 딥살사(Deep SARSA) : 온폴리시(On-policy)인 살사 기반
- 딥-큐러닝(DQN) : 오프폴리시(Off-policy)인 큐러닝 + 인공신경망

DQN

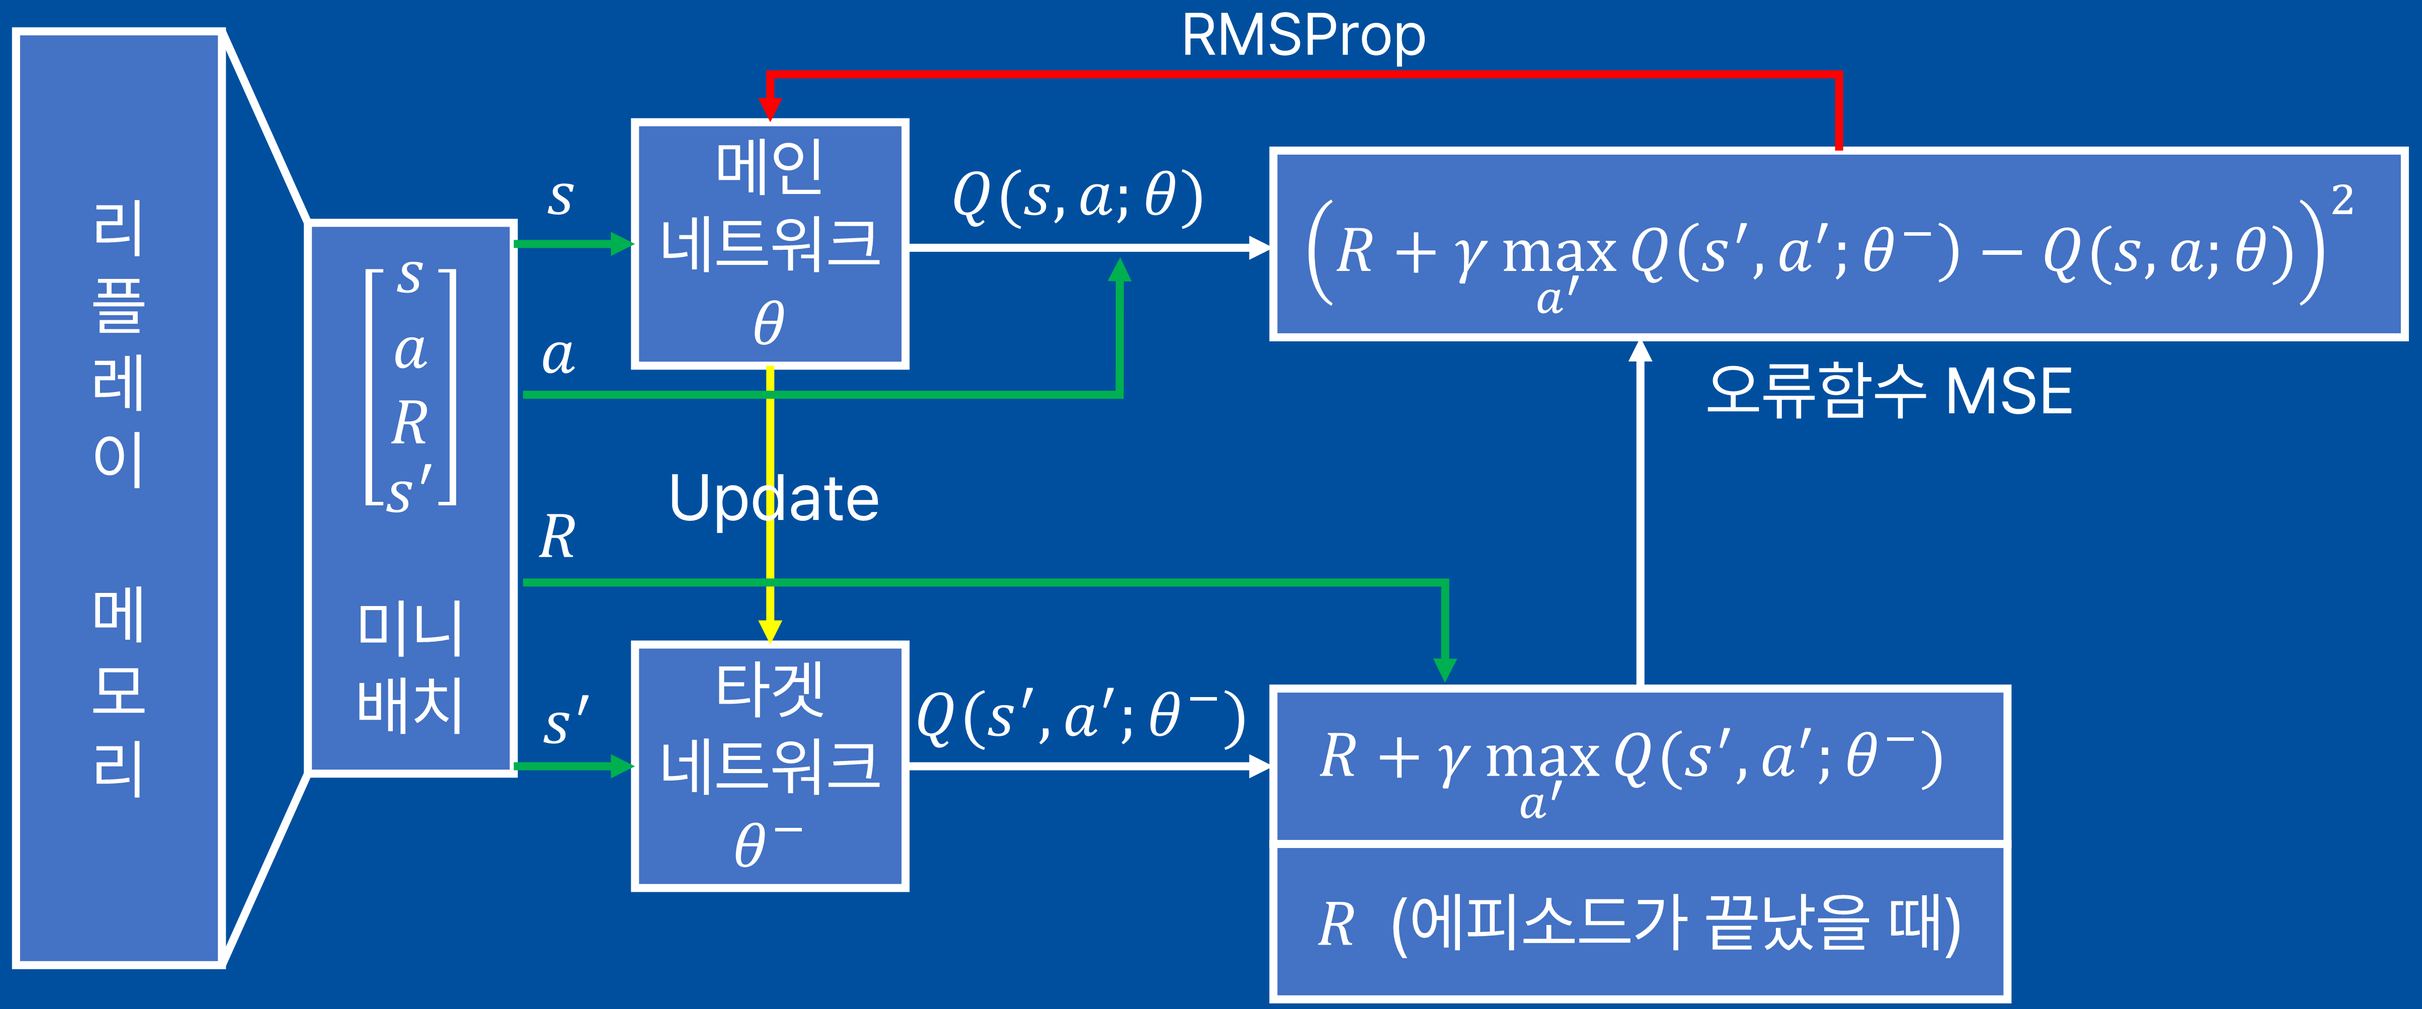
RMSProp
리플레이 메모리
$\begin{bmatrix} s \\ a \\ R \\ s' \end{bmatrix}$
미니 배치
s
a
R
s'
메인 네트워크 θ
타겟 네트워크 θ^-
$Q(s,a;\theta)$
$Q(s',a';\theta^-)$
Update
$\left(R+\gamma \max_{a'} Q(s',a';\theta^-) - Q(s,a;\theta)\right)^2$
오류함수 MSE
$R+\gamma \max_{a'} Q(s',a';\theta^-)$
R (에피소드가 끝났을 때)

DQN

- DQN의 특징
  1. 오프폴리시(Off-policy)
  2. 리플레이 메모리 + 미니 배치
  3. 타겟 신경망

DQN

- 온폴리시(On-policy) vs 오프폴리시(Off-policy)
  - 온폴리시 (예 : 살사)

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha(R_{t+1} + \gamma Q(S_{t+1}, A_{t+1}) - Q(S_t, A_t))$$

  - 학습하는 정책과 행동을 고르는 정책이 항상 같아야 한다.
    - 다음 상태에서 수행한 안 좋은 행동이 현재에 큰 영향을 미친다.
    - 정책을 업데이트하면 과거의 경험들을 학습에 이용 불가능해 비효율적이다.

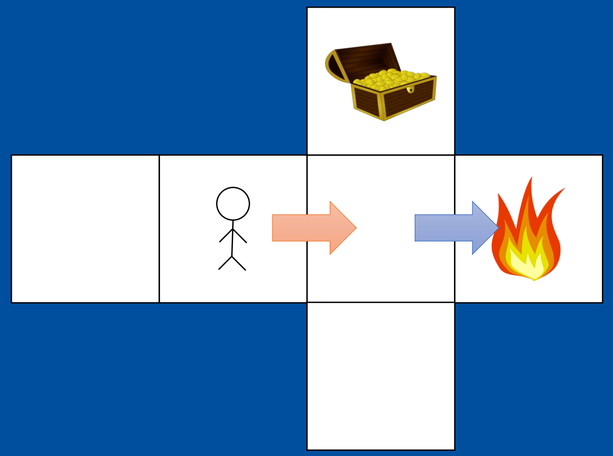

DQN

- 온폴리시(On-policy) vs 오프폴리시(Off-policy)
  - 오프폴리시 (예 : 큐러닝)

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha(R_{t+1} + \gamma \max_{a'} Q(S_{t+1}, a') - Q(S_t, A_t))$$

  - 학습하는 정책과 행동을 고르는 정책이 달라도 된다.
    과거에 경험한 에피소드들도 학습에 계속해서 이용 가능하다. → 효율적

DQN

- 리플레이 메모리 + 미니 배치
  - 강화학습이 잘 일어나기 위해서는 에이전트가
    알 수 없는 데이터들 사이의 연관성이 없어야 한다.
  - 하지만 게임과 같은 환경에서는 데이터들이
    행동에 대한 연속적인 결과이기 때문에 연관성이 심하다.
  - 그래서 데이터들을 리플레이 메모리에 저장하고,
    이 중 샘플을 고르는 미니 배치 방법을 사용한다.

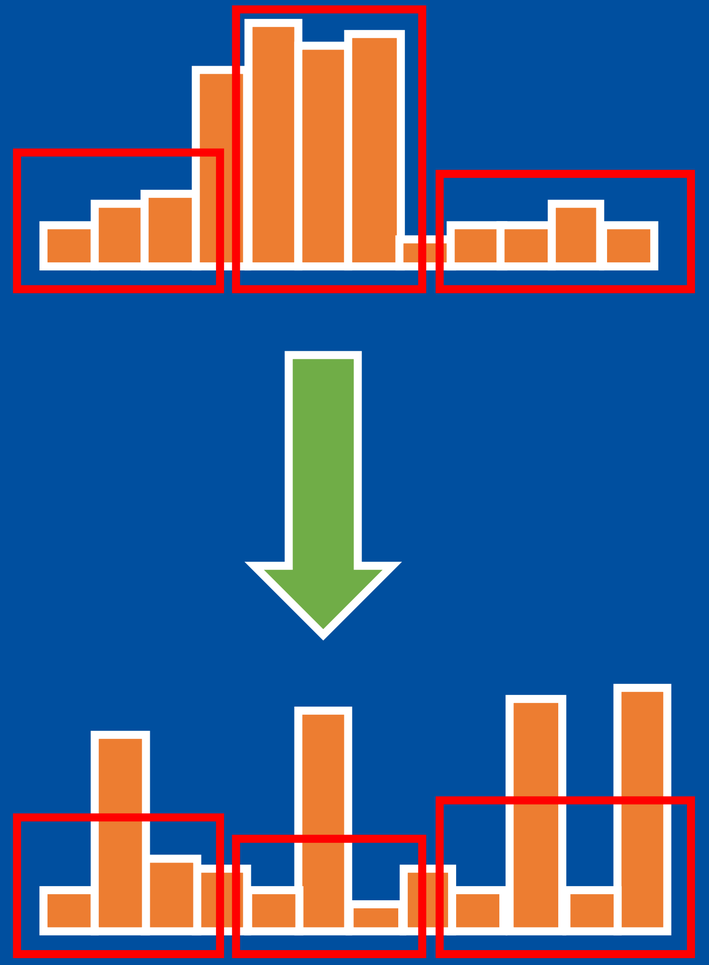

DQN

- 리플레이 메모리 + 미니 배치
  - 리플레이 메모리는 환경에서 받은 $[s, a, R, s']$을 저장한다.
  - 받은 s'를 새로운 s로 에이전트에게 전달해 에피소드를 계속 진행시킨다.

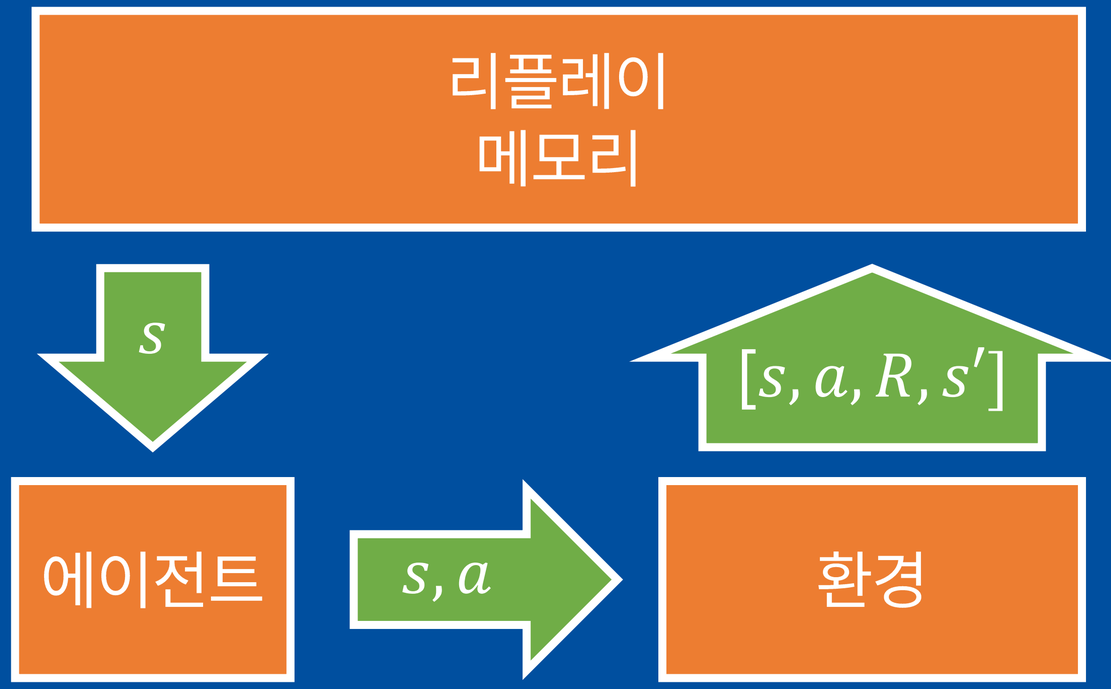

DQN

- 리플레이 메모리 + 미니 배치
  - 리플레이 메모리에 저장되어 있는 $[s, a, R, s']$ 집합에서 일부를 무작위로 샘플링하고, 이걸로 에이전트를 학습시킨다.
  - 이렇게 하면 샘플 사이의 시간적 상관관계가 줄어들고, 살사에서 발생했던 문제를 줄일 수 있다.

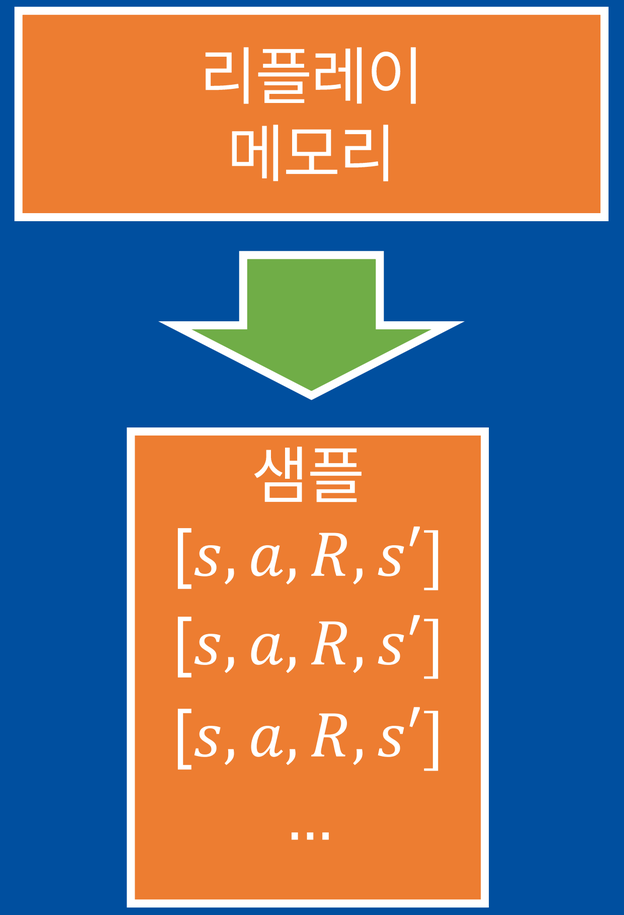

DQN

- 리플레이 메모리 + 미니 배치
  - 사용할 수 있는 메모리의 크기는 유한하므로,
    리플레이 메모리의 크기에 제한을 둬야 한다.
  - 제한 이상으로 경험이 추가되면 오래된 순서대로
    리플레이 메모리에서 지워준다.
  - 그러면 좋지 않은 과거의 경험이 줄어들면서,
    더 좋은 경험이 샘플로 뽑힐 확률이 증가한다.

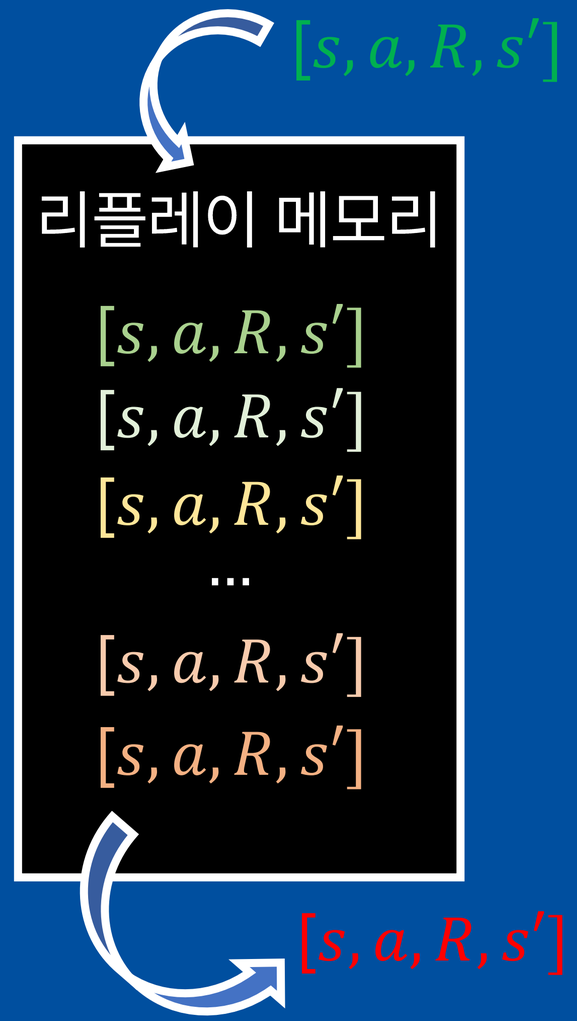

DQN

- 타겟 신경망
  - DQN에서도 딥살사와 비슷하게 오류 함수로 MSE를 사용한다.
  - DQN 에이전트가 학습할 때 사용하는 오류 함수는 아래와 같았다. (2013년)

$$MSE = (\text{정답} - \text{예측})^2 = \left(R_{t+1} + \gamma \max_{a'} Q(s', a'; \theta) - Q(s, a; \theta)\right)^2$$

$$\text{Set } y_j = \begin{cases} r_j & \text{for terminal } \phi_{j+1} \\ r_j + \gamma \max_{a'} Q(\phi_{j+1}, a'; \theta) & \text{for non-terminal } \phi_{j+1} \end{cases}$$

  - 하지만 위 식에는 문제점이 있다. 인공신경망이 스스로 목표를 만들어 내기 때문에 인공신경망이 업데이트될 때 목표가 되는 정답 부분이 계속 변하고, 그 결과 학습이 굉장히 불안하게 이루어진다.

DQN

- 타겟 신경망
  - 그래서 θ^- 를 매개 변수로 갖는 타겟 신경망을 추가한다. (2015년)

$$MSE = (\text{정답} - \text{예측})^2 = \left(R_{t+1} + \gamma \max_{a'} Q(s', a'; \theta^-) - Q(s, a; \theta)\right)^2$$

$$\text{Set } y_j = \begin{cases} r_j & \text{if episode terminates at step j+1} \\ r_j + \gamma \max_{a'} \hat{Q}\left(\phi_{j+1}, a'; \theta^-\right) & \text{otherwise} \end{cases}$$

  - 타겟 신경망은 일정 시간동안 그대로 유지되며 정답을 만들어내다가,
    에피소드가 끝날 때마다 업데이트된다.
    → 이를 통해 학습의 불안정성을 줄일 수 있다.

DQN

1. 상태에 따라 행동을 선택한다.

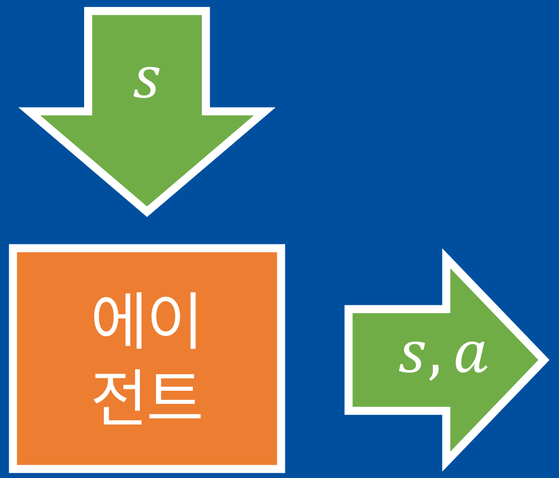

DQN

2. 선택한 행동으로 환경에서 한 스텝을 진행하고,
   샘플을 리플레이 메모리에 저장한다

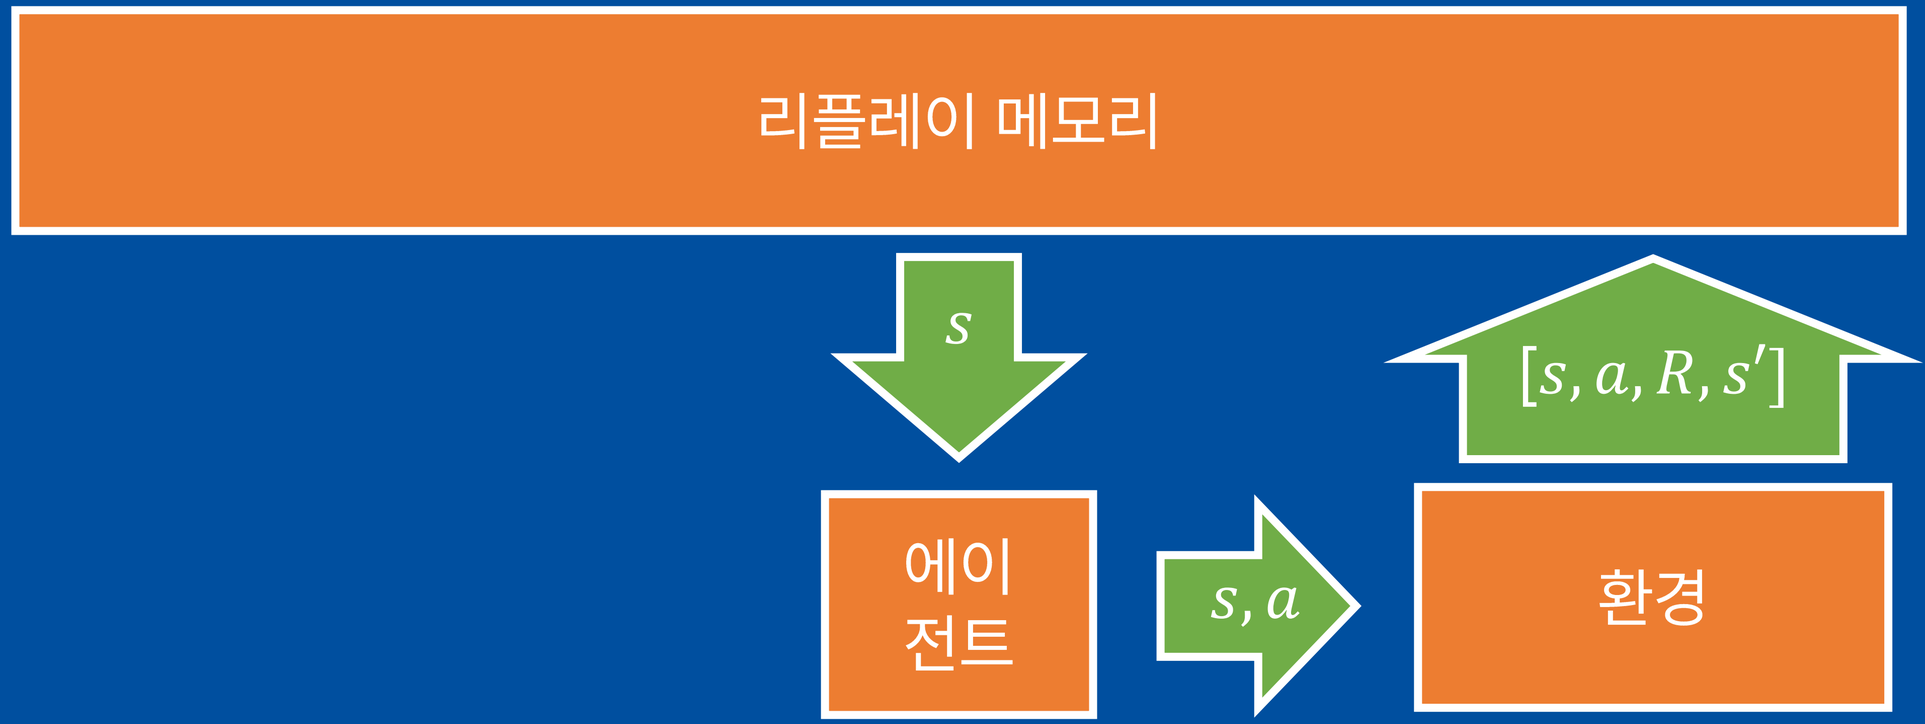

DQN

3. 리플레이 메모리에서 추출한 샘플로 에이전트를 학습시킨다.
4. 에피소드마다 타겟 모델을 업데이트한다.

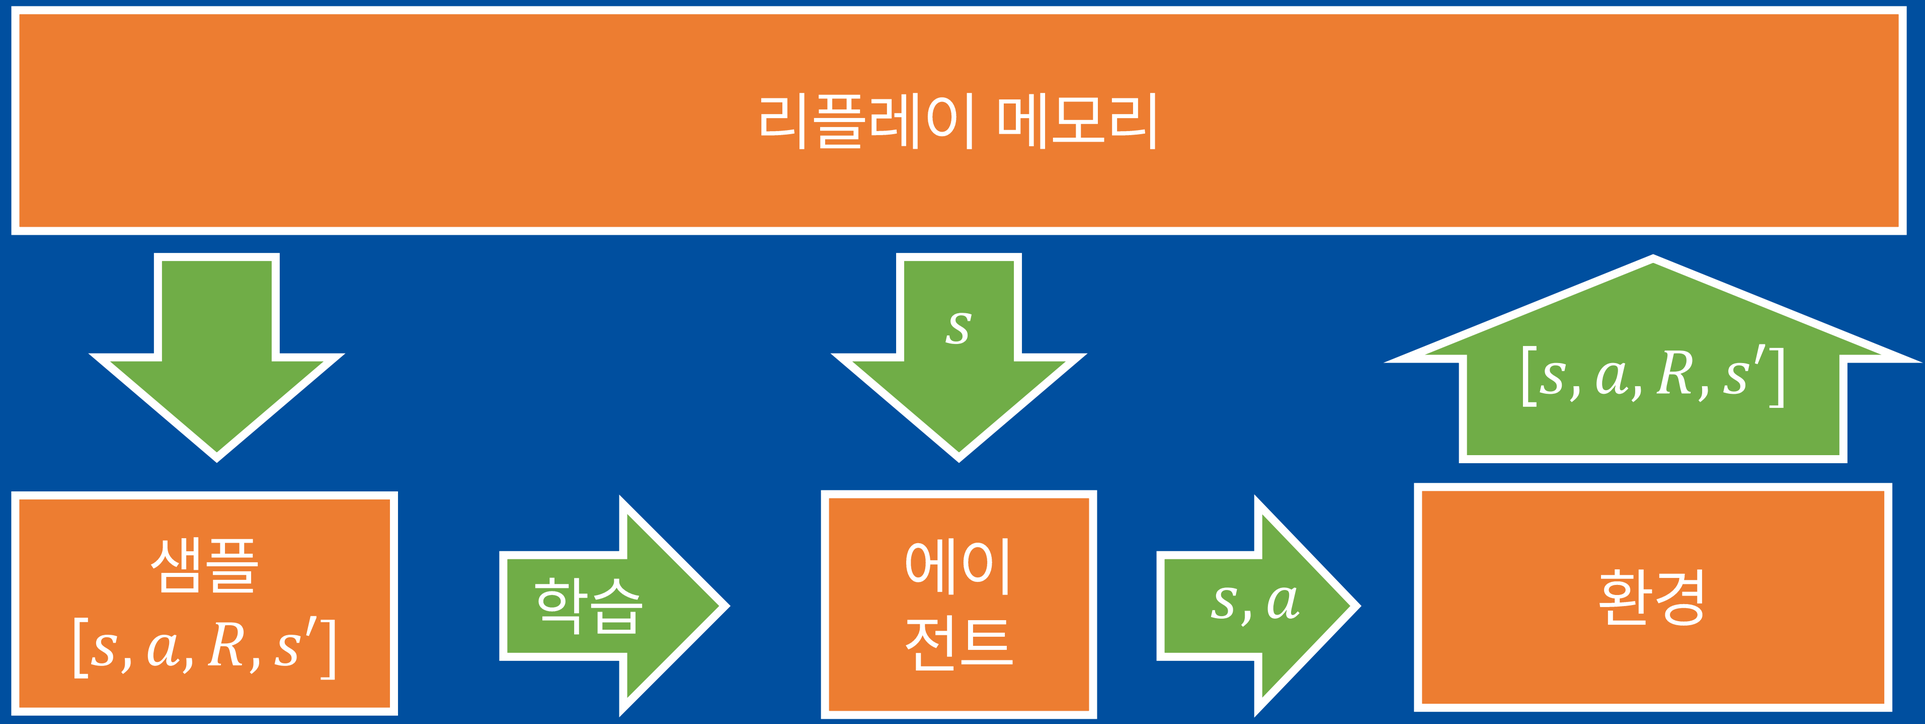

감사합니다!

스터디 듣느라 고생 많았습니다.